OPENCLASSROOMS

10 Mars 2026

Classifiez automatiquement des commentaires toxiques

DataSpace

Thomas Minichetti

Contexte

- Contexte: Test technique de recrutement chez DataSpace, entreprise de data science
- Objectif: Démontrer qu'un modèle NLP récent surpasse les baselines classiques sur une tâche de classification de texte
- Démarche: Veille technologique, identification de modèles récents (<2 ans), preuve de concept sur un dataset réel

DataSpace

Démarche de la preuve de concept

Veille technologique → Baselines (classiques + BERT) → **Modèles récents (Transformers)** → Comparaison & Conclusion

Annonce du plan

1. Dataset/modèles
2. Méthodologie/résultats
3. Dashboard
4. Conclusion

Préparation

Dataset / Modèles

Dataset

- **Kaggle**
- Commentaires wikipedia
- **160 000 commentaires annotés** par des humains
- **6 catégories** de toxicité
- Multi-label
- 10% de commentaires toxiques

Dataset

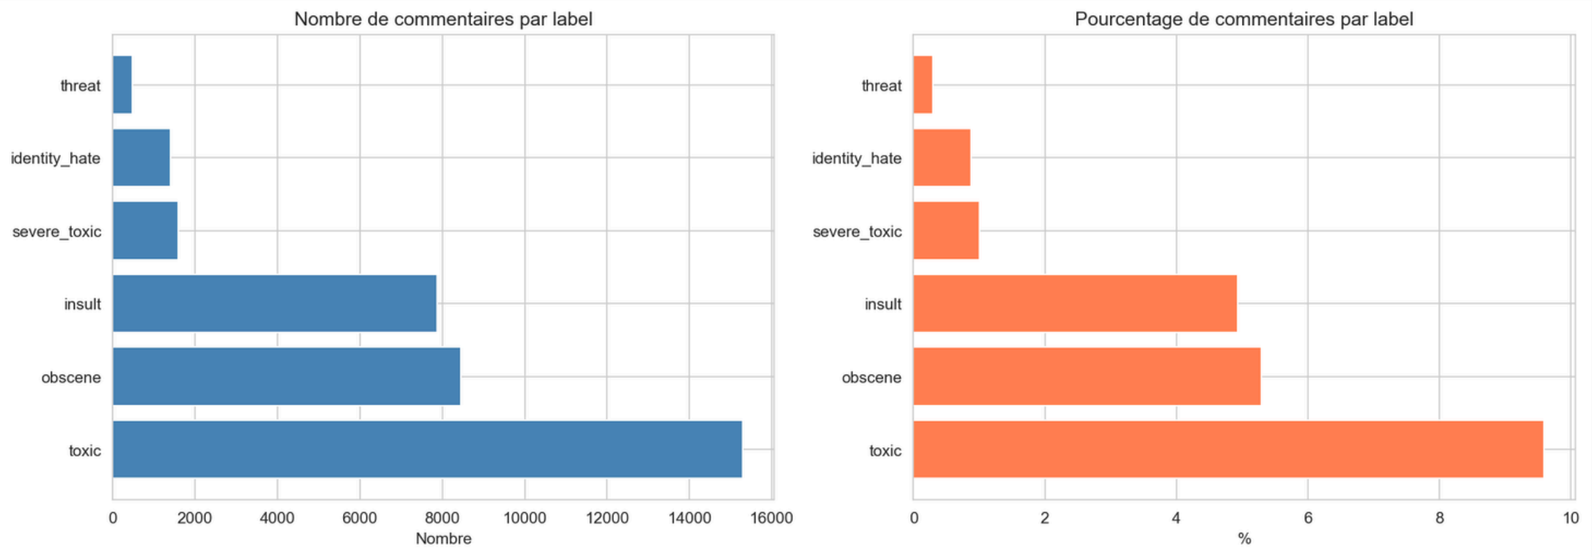
Nombre de commentaires par label
threat
identity_hate
severe_toxic
insult
obscene
toxic
0
2000
4000
6000
8000
10000
12000
14000
16000
Nombre
Pourcentage de commentaires par label
threat
identity_hate
severe_toxic
insult
obscene
toxic
0
2
4
6
8
10
%

Dataset

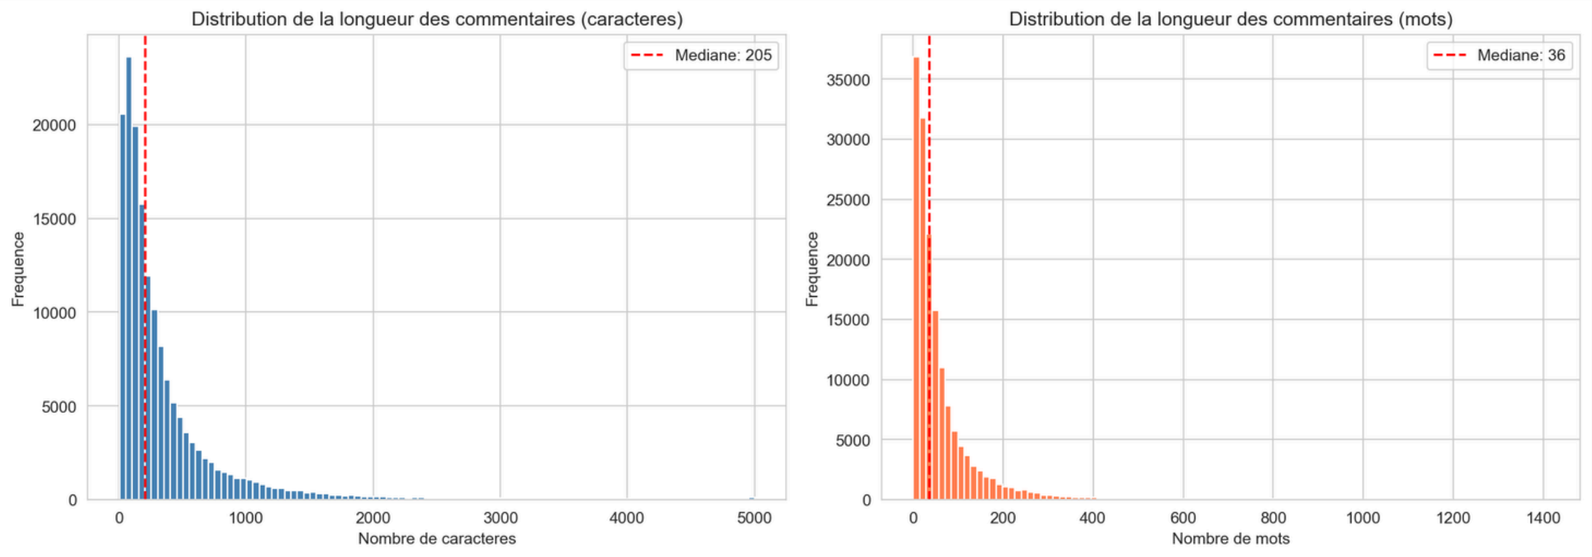
Distribution de la longueur des commentaires (caracteres)
Mediane: 205
Frequence
0
5000
10000
15000
20000
0
1000
2000
3000
4000
5000
Nombre de caracteres
Distribution de la longueur des commentaires (mots)
Mediane: 36
Frequence
0
5000
10000
15000
20000
25000
30000
35000
0
200
400
600
800
1000
1200
1400
Nombre de mots

Dataset

Wordclouds par categorie de toxicite
toxic
severe_toxic
obscene
threat
insult
identity_hate

Modèles sélectionnés

TF-IDF, BERT, ModernBERT

Sources et références

- Devlin 2018 (BERT)
- Warner 2024 (ModernBERT)
- Vaswani 2017 (Transformers)
- Kaggle Jigsaw

Résultats

Méthodologie/résultats

Protocole expérimental

- Split 70/15/15
- ROC-AUC macro
- métriques complémentaires F1/précision/rappel

TF-IDF + Logistic Regression

Description de la méthode vectorisation → classification

BERT

- Architecture bidirectionnelle
- self-attention
- révolution NLP 2018

ModernBERT

- Pré-entraîné sur 2 trillions de tokens
- Performances inégalées

Tableau des résultats

Modèle	ROC-AUC	F1-macro	Précision	Rappel	Train (s)
TF-IDF + LogReg	**0.9786**	0.4666	0.7831	0.3536	19s
BERT	0.9878	**0.6965**	0.6767	0.7240	2933s
ModernBERT	**0.9914**	0.6427	0.7410	0.5749	5057s

Comparaison des performances

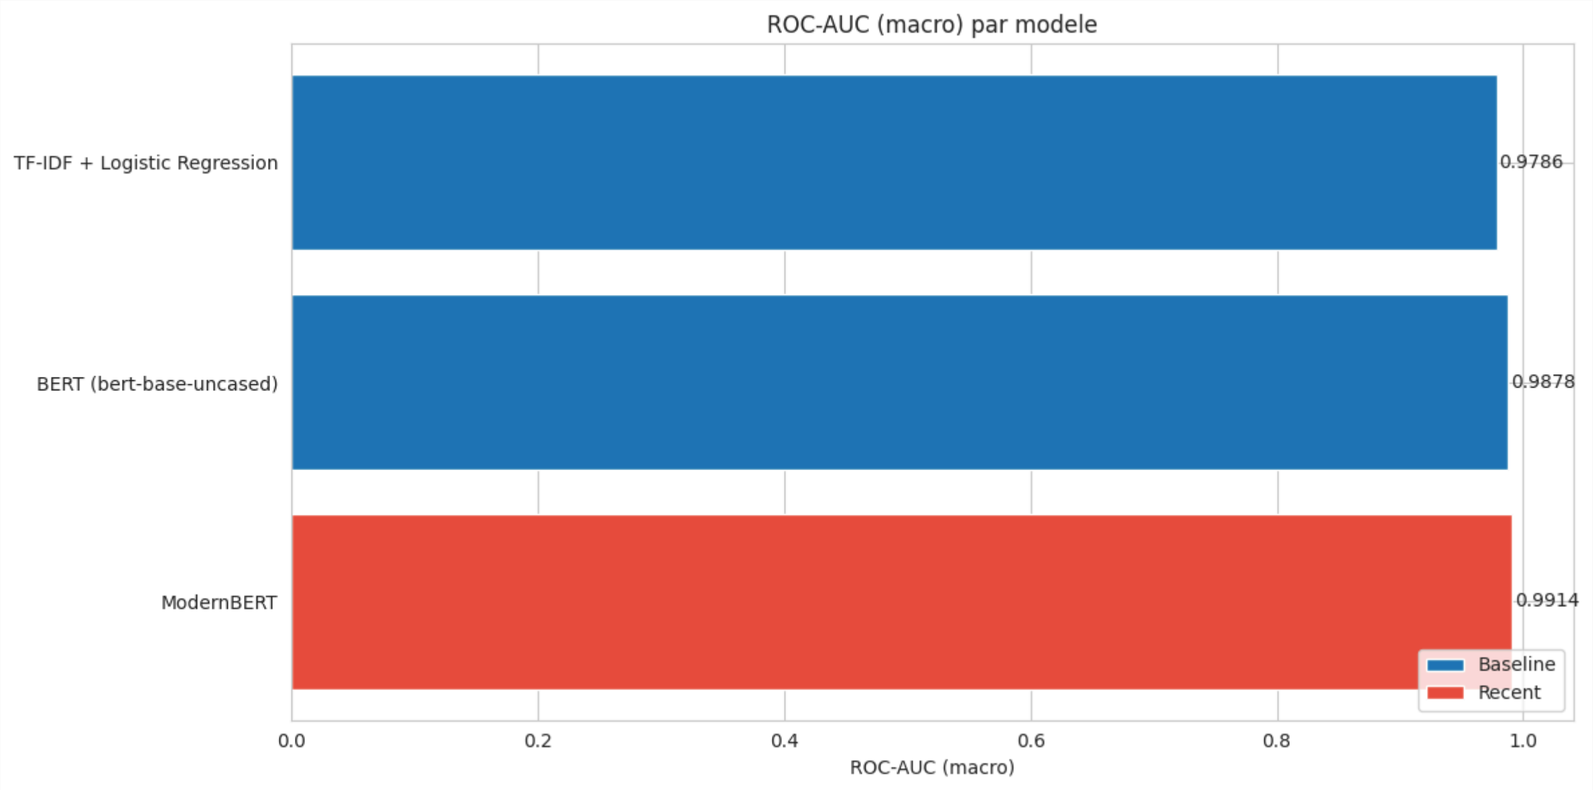

Comparaison des performances

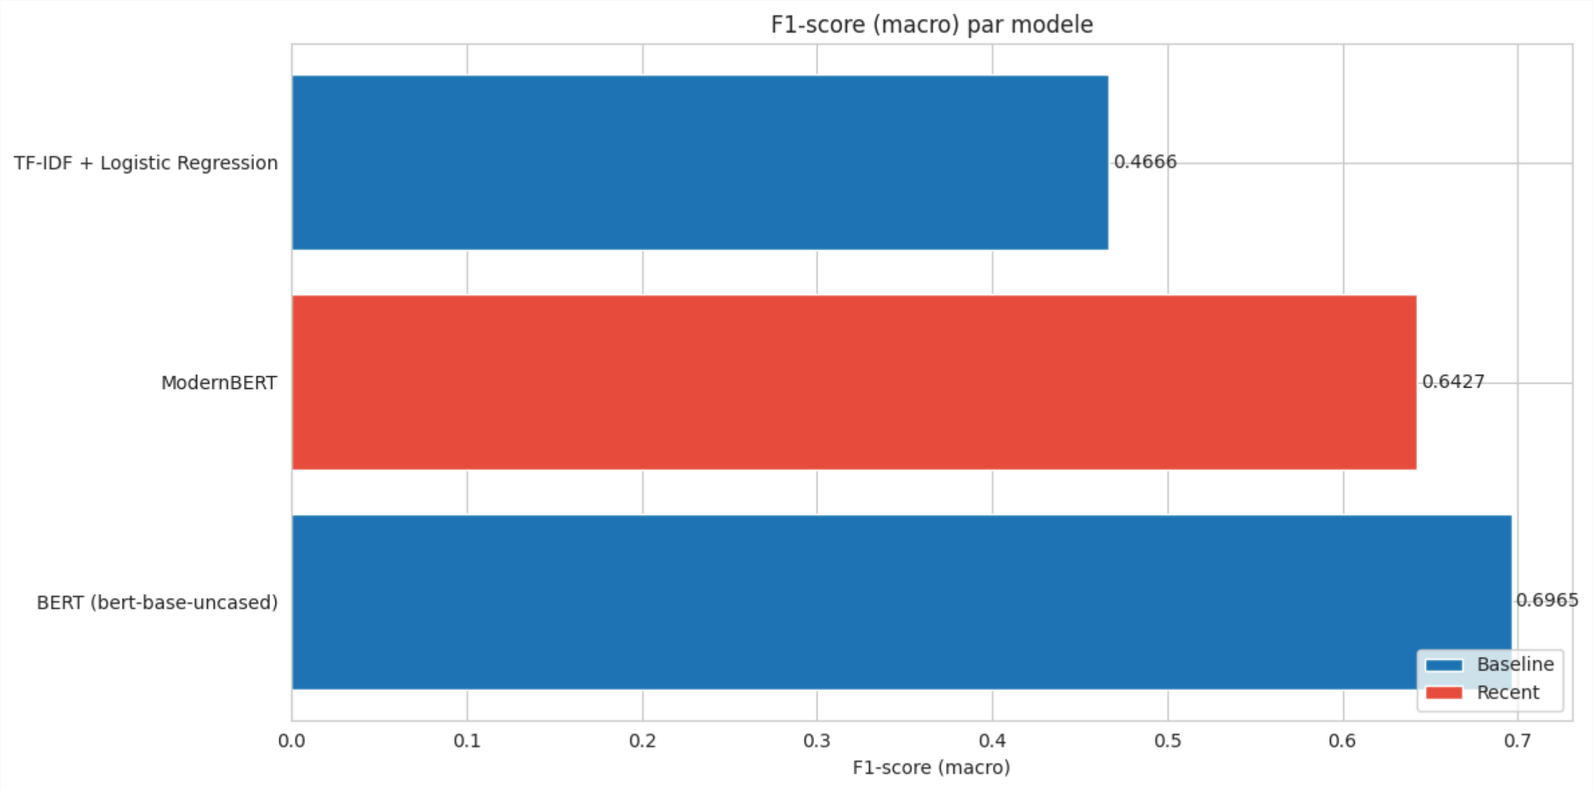

Coût et performance des modèles

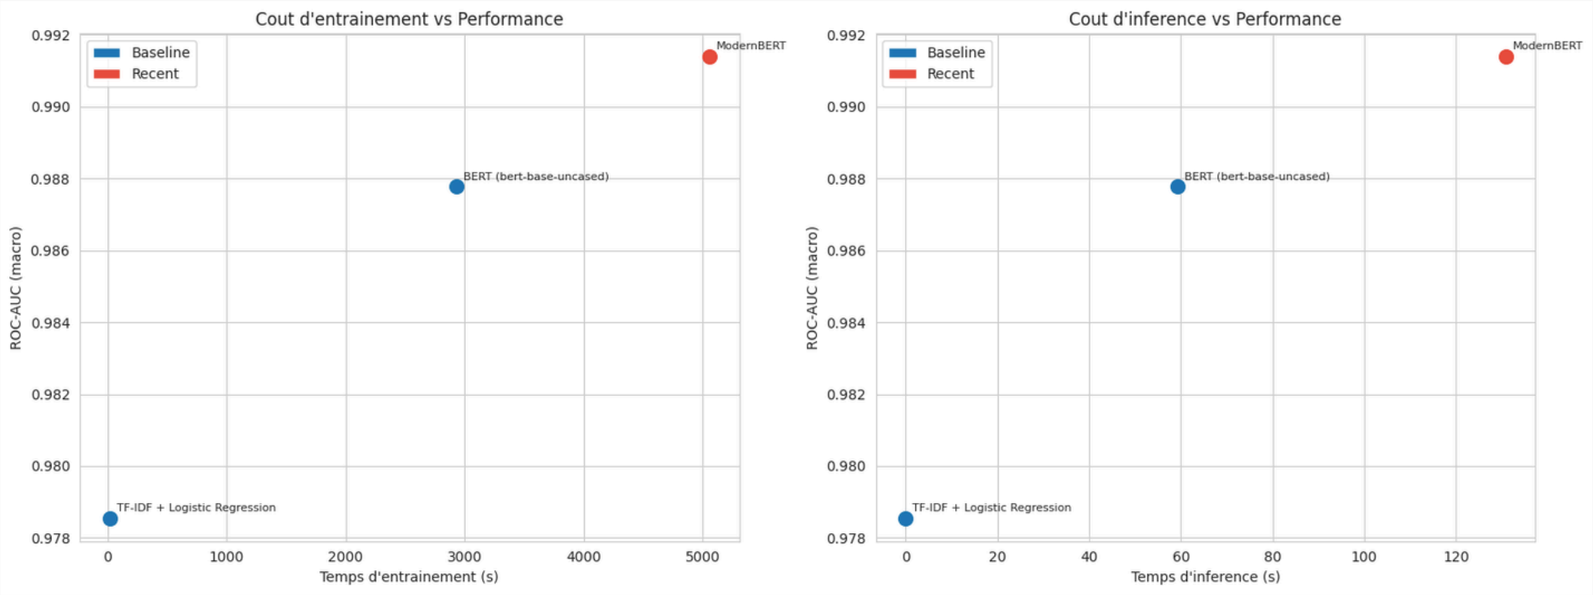

Dashboard

Streamlit

Synthèse

Synthèse des Résultats

Conclusion

Conclusion & Perspectives

Merci de votre écoute

Avez-vous des questions ?